# DLP
# LAB 3

謝侑哲

112550069

Github:

https://github.com/youzhe0305/NYCU-DLP

# 1. Overview

本次 lab 為，使用 UNet, ResNet34+UNet 來做 Binary Semantic Segmentation，本次針對寵物圖片做訓練及應用，使用的資料集為 Oxford-IIIT Pet Dataset。這次主要做的分類是基於 trimap，把圖片分成前景及背景。在評估上則使用 Dice Score 評估 prediction 與 ground truth，把注意力放在前景的分割上。

# 2. Implementation Details

## A. Details of your training, evaluating, inferencing code

### (1) Training Code

Step1 初始化，建立工具:

```
hyper_parameter = {
    'n_epoch': 200,
    'batch_size': 80, # 3312 samples for train
    'learning_rate': 0.001,
    'regularization': 0,
    'bilinear': True,
}

dataset = load_dataset('dataset', 'train')
dataloader = DataLoader(dataset, hyper_parameter['batch_size'], shuffle=True)
if os.path.exists('saved_models/model_Res34_UNet.pth'):
    print('load trained model')
    model = torch.load('saved_models/model_Res34_UNet.pth')
else:
    print('not load model')
    model = ResNet34_Unet(in_channels=3, n_class=2, bilinear=hyper_parameter['bilinear'], device=device)
model.train()
optimizer = torch.optim.Adam(model.parameters(), lr=hyper_parameter['learning_rate'], weight_decay=hyper
```

與 Lab2 的訓練方式類似，先引入 unet.py, resnet34_unet.py 建立好的模型，接著根據之前的訓練結果調整 hyper parameter。

接著把 oxford_pet.py 建立好的 Dataset 引入，設定為 train 模式，取得訓練用的圖片跟 mask，接著再使用 Dataloader 能分 batch 讀取資料，並且做到隨機化(shuffle)，讓每次訓練的資料組合不一樣，增加 Robustness。最後引入一個與論文的 SGD 不同但理論上更好的 Adam optimizer，一個結合了 Momentum 跟 Adaptive Grad 的更新方式。

Step2 訓練過程

```
for epoch in range(hyper_parameter['n_epoch']):
    epoch_loss = []
    for idx, samples in enumerate(dataloader):
        img = samples['image'].type(torch.float).to(device)
        mask = samples['mask'].to(device) # class (2 class)
        trimap = samples['trimap'].to(device) # separete image to 3 clss: 1-front-ground, 2-background, 3-ur
        output = model(img)
        loss = model.get_loss(output, mask)
        loss.backward()
        epoch_loss.append(loss.item())
        optimizer.step()
        optimizer.zero_grad()
    avg_epoch_loss = sum(epoch_loss) / len(epoch_loss)
    validation_loss, validation_dice = evaluate(model, device)
    print(f'epoch: {epoch+1}, training_loss: {round(avg_epoch_loss,4)}, testing_loss: {round(validation_loss
```

首先用 for 迴圈做 n_epoch 次的訓練，接著 enumerate dataloader，每次取得一個 batch 的資料，再把它丟進 model，即可得到 output

接著把 prediction 跟 mask 傳入建在 model 裡的 loss function，因為 segmentation 可以視為 classify 的一個特例，所以這裡使用的跟 lab2 一樣是 CrossEntropy，得到 loss tensor 之後就可以對其做 backward propagation，得到每個 weight tensor 的 grad，使用 optimizer 做更新。

最後，引入 evaluate.py 裡寫得 validation function。測試每個 epoch 的 validation accuracy， 保留最高 accuracy 的參數，避免 epoch 太多導致 overfitting 之後，留到的是 overfitting 的參數。

### (2) Evaluating Code

Evaluating Code 大致上跟 Training Code 相同，只差在 dataset 是取 valid 的部分，並且 model 是作為參數傳入，以便在訓練時，把每個 epoch 的參數與 model 傳入。

```
dataset = load_dataset('dataset', 'valid')
dataloader = DataLoader(dataset, hyper_parameter['batch_size'], shuffle=False)
model = net
model.eval()
```

```
for idx, samples in enumerate(dataloader):
    img = samples['image'].type(torch.float).to(device)
    mask = samples['mask'].to(device) # class (2 class)
    trimap = samples['trimap'].to(device) # separete image t

    output = model(img)

    loss = model.get_loss(output, mask)
    epoch_loss.append(loss.item())

    # batch, channel, H, W
    class_prob = F.softmax(output, dim=1)
    prediction = torch.argmax(class_prob, dim=1)

    dice = dice_score(prediction, mask)
    epoch_dice.append(dice.item())

avg_dice = sum(epoch_dice) / len(epoch_dice)
avg_epoch_loss = sum(epoch_loss) / len(epoch_loss)
return avg_epoch_loss, avg_dice
```

Forwarding 的過程與 training 一樣，這裡唯一的差別就是把 forwarding 的 output 丟入 softmax function，得到屬於前景 or 背景的機率，再取機率大的那方作為 prediction 結果。

之後再用從 utilis.py 引入的 dice_score 計算 prediction 與 mask 的 dice score，用來評估 segmentation 的成果。Dice score 的計算如下:

```
def dice_score(pred_mask, gt_mask):
    # unify to (batch, H, W)
    gt_mask = gt_mask.view(gt_mask.shape[0], gt_mask.shape[2], gt_mask.shape[3])

    epsilon = 1e-6
    # for class only 0,1 dice take 1 part
    common_pixel_1 = torch.sum((pred_mask * gt_mask).type(torch.int), dim=(1,2))
    pred_pixel_1 = torch.sum((pred_mask==1).type(torch.int), dim=(1,2))
    gt_pixel_1 = torch.sum((gt_mask==1).type(torch.int), dim=(1,2))

    dice_score = (2*common_pixel_1 + epsilon) / (pred_pixel_1 + gt_pixel_1 + epsilon)
    return dice_score.mean()
```

首先找兩張圖同樣為 1 的部分，也就是同為前景的部分，計算共同的 pixel 數量有多少，再分別計算兩邊各自有多少為前景的部分。帶入 dice score 的公式，即可計算出，dice score 把評估重點放在我們想要切割的東西，也就是前景上面，比起單純比較差異更能夠體現出分割的效果是否符合需求。

### (3) Inferencing Code

Inferencing 跟 evaluating 的寫法幾乎一樣，forward、評估的方式也相同，唯一的差別在於使用了 dataset 的不同部分，這裡使用的是 test 的部分。

```
dataset = load_dataset('dataset', 'test')
dataloader = DataLoader(dataset, hyper_parameter['batch_size'], shuffle=False)
model = torch.load('saved_models/model_Res34_UNet.pth')
model.eval()
```

## B. Details of your model (UNet & ResNet34_UNet)

### (1) UNet

(UNet 參考以下網址實作及修改:
https://github.com/milesial/Pytorch-UNet/blob/master/unet/unet_parts.py)

UNet 基於 CNN，主要是用來處理圖片的 segmentation 任務，透過 shortcut connection 來讓分割的準度提升，網路架構圖如下，其主要分成 2 個 path，我將就這兩個 path 分別解釋:

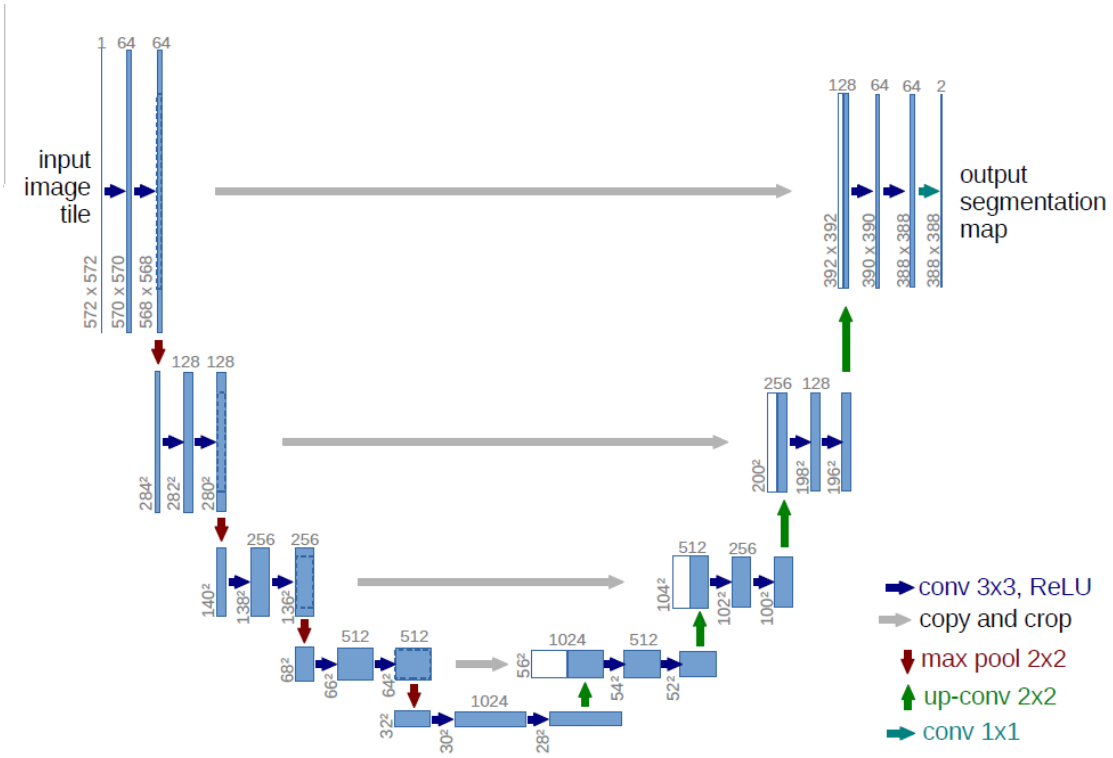


(UNet 架構圖)

- **Contracting Path:**

於架構圖中左側的部分，顧名思義，是用來把圖片縮小、提取重要特徵成 representation，之後再將 representation 交由後段的 expansive path decode 成 segmentation 圖。

其中有兩個重要的部分，Convolution 與 Pooling，可以看見 contracting path 都是由 2 個 Convolution+1 個 Pooling 的 Block 組成的，這兩個合稱為 Down Sampling，可以降低圖片的大小(解析度)，並且只保留對 segmentation 重要的特徵。每次 Down Sampling 都會讓圖片縮小 1/4，feature channel 則加深 2 倍。實作如下:

```
DoubleConv(nn.Module):
def __init__(self, in_channels, mid_channels, out_channels):
    super().__init__()
    self.first_conv = nn.Sequential(
        # padding = 1 -> maintain same size
        nn.Conv2d(in_channels=in_channels, out_channels=mid_channels, kernel_size=(3,3), padding_mode='reflect
        nn.BatchNorm2d(mid_channels), # feature channel
        nn.ReLU()
    )
    self.second_conv = nn.Sequential(
        nn.Conv2d(in_channels=mid_channels, out_channels=out_channels, kernel_size=(3,3), padding_mode='reflec
        nn.BatchNorm2d(out_channels), # feature channel
        nn.ReLU()
    )

def forward(self, x):
    x_mid = self.first_conv(x)
    x_out = self.second_conv(x_mid)
    return x_out
```

首先建立兩層 Convolution 的 model 為 DoubleCov，並在每個 Convolution 後面加上 Batch Normalization 降低梯度消失或爆炸的問題，再補上 ReLU 增加 non-linear 的效果。接著把 MaxPooling 跟 DoubleConv 拼再一起，成為一個完整個 Down Sampling，對應到架構圖中就是一個向下的紅色箭頭與兩個向右的藍色箭頭。

另外，paper 中有提到，使用 mirror 做 padding 可以更好的減少邊界訊息的損失，因此這裡使用 reflect-padding 來做 padding，避免圖片在 Convolution 的過程中縮小，也不會因為 padding 導入差異很多的邊界訊息。

有了 Down Sampling 就可以把 contracting path 建出來，如下圖所示:

```
self.constracting_path_part1 = DoubleConv(in_channels=in_channels, mid_channels=64, out_channels=64)
self.constracting_path_part2 = DownSampling(in_channels=64, mid_channels=128, out_channels=128)
self.constracting_path_part3 = DownSampling(in_channels=128, mid_channels=256, out_channels=256)
self.constracting_path_part4 = DownSampling(in_channels=256, mid_channels=512, out_channels=512)
self.constracting_path_part5 = DownSampling(in_channels=512, mid_channels=1024//factor, out_channels=1024//f
```

- Expansive Path

架構圖的右側部分，類似於 decoder 的功能，可以把 contracting 提取出來的 representation 重新轉回正常大小的圖片。與 contracting path 的做法類似，這部分的實作上，我把 2 個 Convolution 與 1 個 up-convolution 統合成 Up Sampling，可以用來將圖片恢復成原來的大小，並且把儲存在 feature channel 中的特徵整合在一起，變成之後 segmentation 分類的依據。實作如下

```python
class UpSampling(nn.Module):
    def __init__(self, in_channels, mid_channels, out_channels, bilinear=True): # bilinear set True for preli

        if bilinear == True:
            # about align_corner: True: make source points on corner, False: make source point on crosshatch
            # ref: https://blog.csdn.net/wangweiwells/article/details/101820932
            self.up_conv = nn.Upsample(scale_factor=2, mode='bilinear', align_corners=True)
            self.conv = DoubleConv(in_channels, mid_channels, out_channels)
        else:
            # channel / 2 for add concat channel
            # strid-1 = the pixel between 2 source pixel
            # kernel_size - padding - 1 = padding number
            # Height = (s*(height-1)+1)+(k-p-1)*2 - (k-1) = s*height + k - 2*p - s, Width same method
            # ref: https://blog.csdn.net/qq_37541097/article/details/120709865
            self.up_conv = nn.ConvTranspose2d(in_channels, out_channels=in_channels//2, kernel_size=(2,2), st
            self.conv = DoubleConv(in_channels, mid_channels, out_channels)


    def forward(self, x, concat):
        # (batch, channel, height, width)
        x = self.up_conv(x) # half
        concated_x = torch.cat((concat, x), dim=1) # concat img from constracting path, get high resolution f
        return self.conv(concated_x)
```

Up-convolution 的做法有兩個，一個是直接使用 Bilinear 插值的方式，把圖片直接放大，另一個是使用 Transposed Convolution 放大，Transposed Convolution 透過把原圖的 pixel 之間與外圍 padding 變大，再套入一般的 Convolution 的方式，把 padding 值與原值以學習過的 kernel 補成可以顯現特徵的值，並調整到正確的大小。

兩種方式各有好處，Bilinear 的優勢在於不需要學習，並且做起來更快速，所以減少參數量的同時，訓練時間可以很大程度的減少，缺點就是 model 的 capacity 會下降，可能會導致沒辦法找出很好的解。Transposed Convolution 則是用更多的參數來學習，訓練的會更慢，但是可以提升 model 的 capacity，適合再應對更複雜的資料時使用。

之後，用到 UNet 的一大特色: concat connection，把 contracting path 中得到的高解析度資料，直接 concat 到現有資料上，讓模型可以同時使用高解析度的資料與精煉過後的重要資料，再使用上述提到的 Double Convolution 做整合，就可以把資料做更好的特徵提取。

接著把 Upsampling 作好幾層，就可以組成 expensive path 了，實作如下，其中除以 factor 的部分是用來應對 bilinear 並不會改變 feature channel 深度的狀況，做出的深度調整。

```
self.constracting_path_part1 = DoubleConv(in_channels=in_channels, mid_channels=64, out_channels=64)
self.constracting_path_part2 = DownSampling(in_channels=64, mid_channels=128, out_channels=128)
self.constracting_path_part3 = DownSampling(in_channels=128, mid_channels=256, out_channels=256)
self.constracting_path_part4 = DownSampling(in_channels=256, mid_channels=512, out_channels=512)
self.constracting_path_part5 = DownSampling(in_channels=512, mid_channels=1024//factor, out_channels=1024

self.expansive_path_part1 = UpSampling(in_channels=1024, mid_channels=512//factor, out_channels=512//facto
self.expansive_path_part2 = UpSampling(in_channels=512, mid_channels=256//factor, out_channels=256//factor
self.expansive_path_part3 = UpSampling(in_channels=256, mid_channels=128//factor, out_channels=128//factor
self.expansive_path_part4 = UpSampling(in_channels=128, mid_channels=64, out_channels=64, bilinear=bilinea
self.output = nn.Sequential(
    nn.Conv2d(in_channels=64, out_channels=n_class, kernel_size=(1,1), padding_mode='reflect', padding=0)
)
```

### (1) ResNet34-UNet

(ResNet34 部分參考以下網址實作及修改:
https://github.com/chenyuntc/pytorch-practice/blob/master/models/ResNet34.py)

這個網路模型是把 ResNet34 與 UNet 的 expansive path 拼在一起，一個做為 encoder 另一個做為 decoder 的形式。以下將會先就 ResNet34 做解釋，再提他們是怎麼合在一起的。

- ResNet34

ResNet 全稱 Residual Net，其使用了一個稱為 residual mapping 的方法，用來解決 degradation 的問題。residual mapping 的方法是建立一個" shortcut connection" ，直接把幾個 layer 前的資料用 identity 的方式原封不動加回幾個 layer 的輸出，如下圖。Layer 學習的東西就會從一般的輸出，變成學習輸出與原本資料的差異，也就是所謂的 residual。

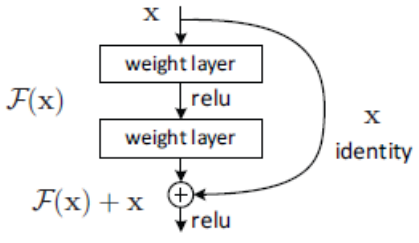


Figure 2. Residual learning: a building block.

學習 Residual 的好處在於，一般的神經網路在加深之後，可能不需要這麼深就會有解，所以理論上的最佳解釋後面的幾層都做恆等映射。但是對於網路來說要學出衡等映射本身是困難的，這就導致一個在少量層數有最佳解的問題，在層數加深之後，反而得到的解更差，或至少得花更多時間去訓練出衡等映射，這個問題稱為 degradation 問題。而如果 layers 學習的是 residual，那要達到恆等映射只要讓 residual 歸零就好，這對於網路而言是相對容易學習的，尤其用了 ReLU 之類的 activation function，只要是負數的任意值，都可以做到，因此降低了 degradation 問題的影響，可以讓網路變得更多層。

ResNet34 就是用了 residual mapping 方法的 CNN，其總共有 34 層，架構圖如下所示:

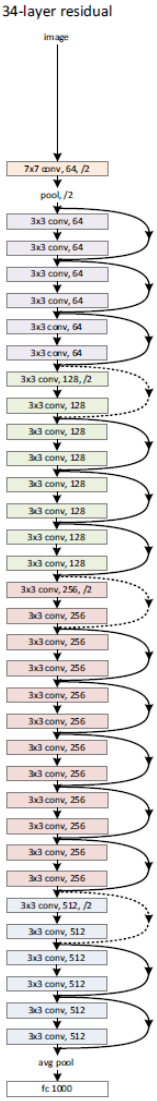

這個架構跟 UNet 的 contracting path 非常像，因此就直接被拿來取代 contracting path 作為 encoder 使用。

- ResNet34-UNet

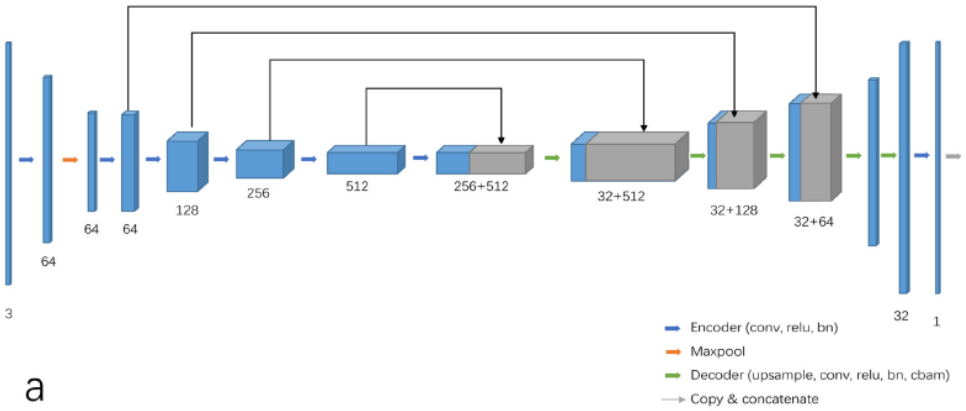


a

如圖所示，左邊 encoder 的部分是 ResNet34，圖中畫出了 ResNet34 的 6 個部分，其中可以再對應到上面 ResNet34 的詳細圖。右側則是 UNet 的 expansive path，把 ResNet 每個 part 的資料再 concat 過去就成功地把它拼在一起了。

- **實作**

首先從 ResNet 的基本單元做起，基本單元如下圖，由 2 個 Convolution layer 構成，在這兩個 Convolution 的前後連了一條 shortcut connection。

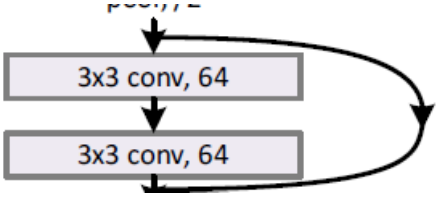


實作於下圖，在 Convolution Layer 的後面一樣會加上 Normalization 與 ReLU，分別處理梯度的消失、爆炸與 non-linear 的問題。接著建立一個 shortcut connection，實務上因為會有 down sampling 的狀況，所以視條件判斷是否要用 Convolution 來調整 residual mapping 映射過去的資料的大小及 feature channel 深度。另外也實作了 make_layer function 用來疊起大數量的 ResBlock。

```python
class ResBlock(nn.Module): # layers with one shortcut connection
    def __init__(self, in_channels, out_channels, downsampling=False):
        super().__init__()
        self.downsampling = downsampling

        stride = 2 if downsampling == True else 1 # when block in tail of one part, use stride 2 to scale dow
        self.model = nn.Sequential(
            nn.Conv2d(in_channels=in_channels, out_channels=out_channels, kernel_size=(3,3), stride=1, paddin
            nn.BatchNorm2d(out_channels),
            nn.ReLU(),
            nn.Conv2d(in_channels=out_channels, out_channels=out_channels, kernel_size=(3,3), stride=stride,
            nn.BatchNorm2d(out_channels),
        )
        if downsampling == True: # shortcut will be 2 times larger than x, use conv to make shortcut smaller.
            self.shortcut_connection = nn.Sequential(
                nn.Conv2d(in_channels=in_channels, out_channels=out_channels, kernel_size=(3,3), stride=2, pa
                nn.BatchNorm2d(out_channels),
                nn.Identity()
            )
        elif in_channels != out_channels: # image will be same, channel will be changed…
        else:
            self.shortcut_connection = nn.Identity()
        self.relu = nn.ReLU()
```

```python
make_part(self, n_block, in_channels, out_channels, downspmpling = True):

part = nn.Sequential()
part.append(ResBlock(in_channels, out_channels, downsampling=downspmpling))
for i in range(n_block-1):
    part.append(ResBlock(out_channels, out_channels))
return part
```

得到 ResBlock 之後，接著把 UNet 的 UpSampling 拿過來做一點修改，主要修改了 UNet 會先把原資料的 feature channel 砍半再拿來 concat 的部分，以及某些 UpSampling 沒有做資料 concat，只有單純的 UpSampling。

```python
class UpSampling(nn.Module):
    def __init__(self, in_channels, mid_channels, out_channels, bilinear=True): # bilinear set
        super().__init__()

        if bilinear == True:
            self.up_conv = nn.Upsample(scale_factor=2, mode='bilinear', align_corners=True)
            self.conv = DoubleConv(in_channels, mid_channels, out_channels)
        else:
            self.up_conv = nn.ConvTranspose2d(in_channels, out_channels=in_channels, kernel_si
            self.conv = DoubleConv(in_channels, mid_channels, out_channels)
        # self.norm = nn.BatchNorm2d(in_channels)

    def forward(self, x, concat=None):
        # (batch, channel, height, width)
        if concat != None:
            concated_x = torch.cat((concat, x), dim=1) # concat img from constracting path, ge
        else:
            concated_x = x
        up = self.up_conv(concated_x) # half
        # up = self.norm(up)
        return self.conv(up)
```

接著把各個組件分配對應的參數，初始化在網路中

```
self.Res_part1 = nn.Sequential(
    nn.Conv2d(in_channels=in_channels, out_channels=64, kernel_size=(7,7), stride=2, paddi
    nn.BatchNorm2d(64),
    nn.ReLU(),
    nn.MaxPool2d(kernel_size=(3,3), stride=(2,2), padding=(1,1) ) # scale down 2
)
self.Res_part2 = self.make_part(3, in_channels=64, out_channels=64, downspmpling=False)
self.Res_part3 = self.make_part(4, in_channels=64, out_channels=128) # scale down 2
self.Res_part4 = self.make_part(6, in_channels=128, out_channels=256) # scale down 2
self.Res_part5 = self.make_part(3, in_channels=256, out_channels=512) # scale down 2
self.Res_part6 = self.make_part(1, in_channels=512, out_channels=256, downspmpling=False)
self.expansive_path_part1 = UpSampling(in_channels=256+512, mid_channels=32, out_channels=
self.expansive_path_part2 = UpSampling(in_channels=32+256, mid_channels=32, out_channels=3
self.expansive_path_part3 = UpSampling(in_channels=32+128, mid_channels=32, out_channels=3
self.expansive_path_part4 = UpSampling(in_channels=32+64, mid_channels=32, out_channels=32
self.expansive_path_part5 = UpSampling(in_channels=32, mid_channels=32, out_channels=32, b
```

最後如下圖，把組件串在一起，把對應的 concat 對象作為參數傳入，就完成了 ResNet34-UNet 的建構。

```
def forward(self, x):
    '''
        c1                                      d5
          c2              ->              d4
            c3            ->          d3
              c4          ->      d2
                c5        ->  d1
                c6
    '''
    c1 = self.Res_part1(x)
    c2 = self.Res_part2(c1)
    c3 = self.Res_part3(c2)
    c4 = self.Res_part4(c3)
    c5 = self.Res_part5(c4)
    c6 = self.Res_part6(c5)

    d1 = self.expansive_path_part1(c6, c5)
    d2 = self.expansive_path_part2(d1, c4)
    d3 = self.expansive_path_part3(d2, c3)
    d4 = self.expansive_path_part4(d3, c2)
    d5 = self.expansive_path_part5(d4)
    output = self.output(d5)
```

# 3. Data Preprocessing

## A. How you preprocessed your data?

Data 的 preprocess 上，我主要實驗了兩個方法，第一個方法是在 UNet 論文中寫到的 Elastic Deformation，他可以模仿物理上的彈性變化，把圖片做形變再用 Bicubic 插值法把值填上，以此來擴增資料集比較少見的變化。第二個方法是 Random Crop，隨機切割圖片上的一部份並放大成原圖片的大小，這算是一個在

segmentation 任務上常見的 data augmentation 方法，透過隨機切割圖片可以讓模型針對某些部分的特徵能有更好的學習，而不是總學習一個整體。另外，我也有嘗試使用水平翻轉與垂直翻轉等方法，但初步試驗中，發現這兩個方法對於整體的 evaluation loss 並沒有提升，反而有下降的情況，因此把這兩種方法排除。

實作如下圖，使用 torchvision 的 transform，在每次 dataset getitem 時，就會套用轉換。MyTransforms 的 class 則是用來讓他能同時轉換 image, mask, trimap。

```
training_data_transform = My_transforms(transforms.Compose([ # 因為放在Compose外面，所以image, mask, tri
    transforms.Resize((256,256)),
    transforms.RandomChoice([
        #transforms.RandomHorizontalFlip(p=0.2),
        #transforms.RandomVerticalFlip(p=0.2),
        transforms.RandomApply([
            transforms.ElasticTransform(alpha=30, interpolation=transforms.InterpolationMode.BICUBIC)
        ], p=0.2),
        transforms.RandomApply([
        transforms.RandomCrop((256,256)),
        ], p=0.2),
    ]),
    transforms.Resize((256,256)),
    ]),
)
```

## B. What makes your method unique?

首先看到底下三張實驗結果，模型為 Res34-UNet，其分別代表:1. 沒有套用 data augmentation、套用以 0.2 機率 elastic deformation、以 0.2 機率套用 elastic deformation 或 random crop。分別依 0.001 learning rate 使用 Adam optimizer 訓練 100 epoch 的結果圖。

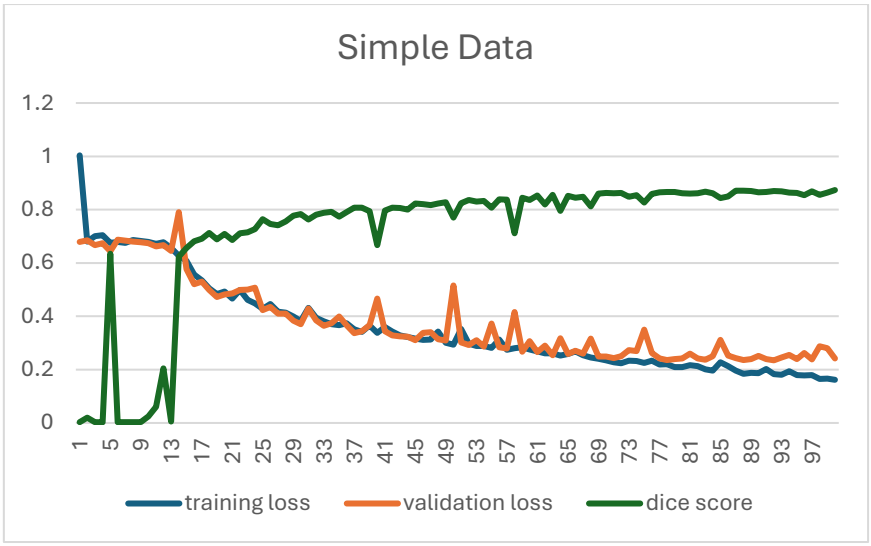


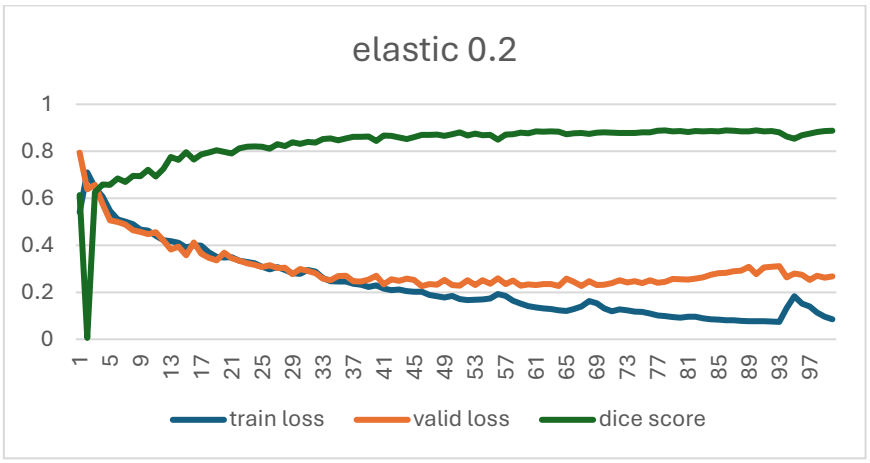


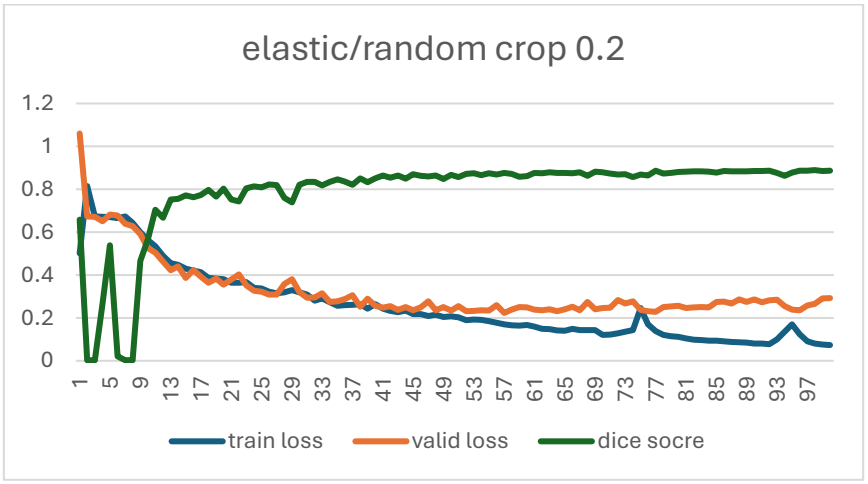


可以看出，三者在最後收斂的 dice socre 與 validation loss 並沒有太大的差別。但是使用了 data augmentation 的組別，validation 下降的速度卻比沒使用 data augmentation 的更快，代表透過 data augmentation 訓練讓模型的泛化能力更快的成長，可以用更少的運算資源得到相同的效果。

另外，data augmentation 理論上應該要增加模型的泛化效果的上限，讓 validation loss 應該要更低於沒有使用 data augmentation。但這裡並沒有這個

現象，我認為是因為我採用的方式是，直接用形變後的圖片取代原圖，而不是多複製一份的方式，因此在形變之後，會少了一份原本的訓練數據，形成一個 trade-off，讓整體只有下降速度變快，卻沒有降更低。針對這個問題，之後可以改良 data augmentation 的方式，把形變之前的結果多複製一份作訓練。

另外，以下 3 張圖為 UNet 套用不同 data augmentation 的結果，得到的結果基本上跟 Res34-UNet 相同，不過收斂之後 overfitting 的狀況更加明顯一點。

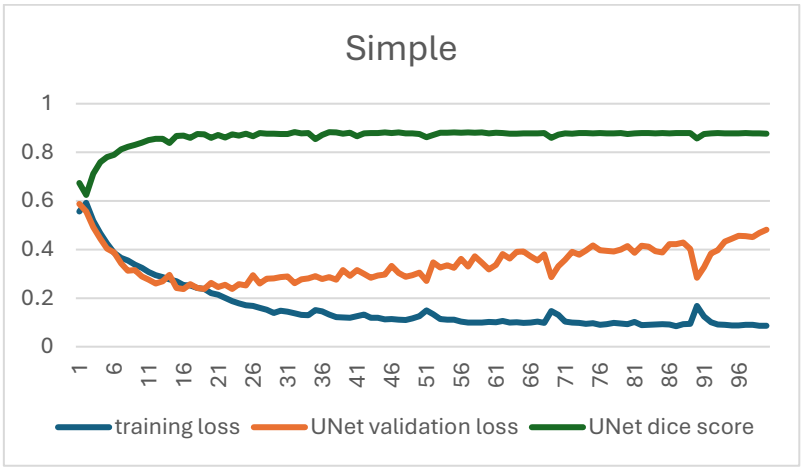


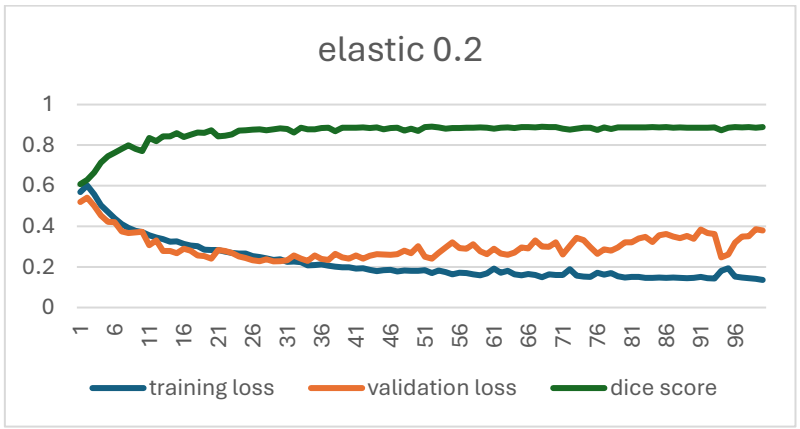


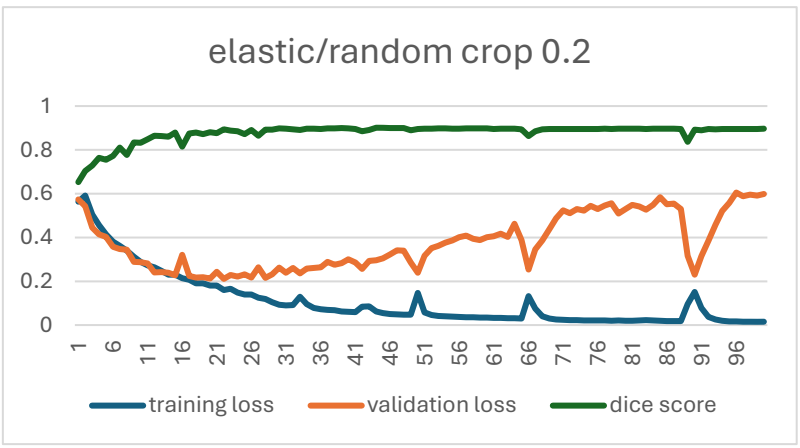

# 4. Analyze on the experiment results

## A. What did you explore during the training process?

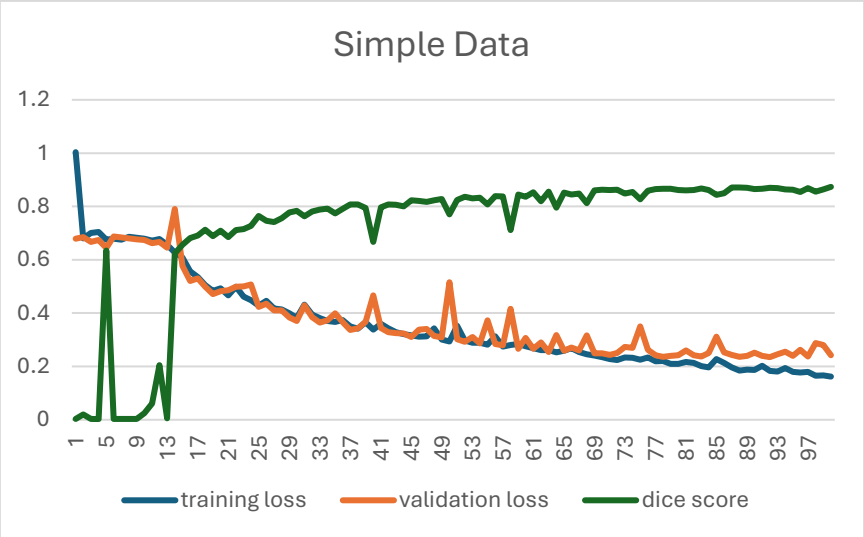


(Res34-UNet)

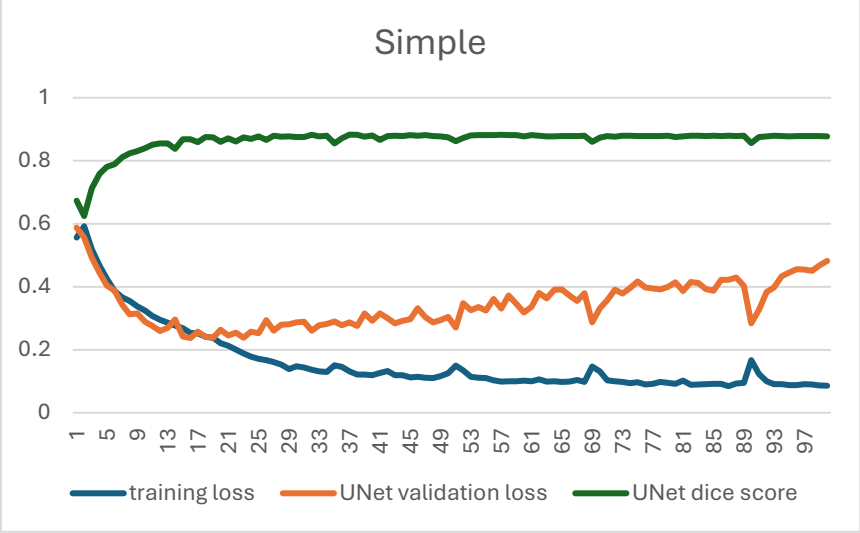


(UNet)

上圖與 3-B 的圖相同，從中可以發現在訓練這個資料集時，很容易產生 overfitting 的問題，也就是 training loss 與 validation loss 的兩條線開始叉開，當兩條線開始叉開時，dice score 就會陷入停滯狀態。因此，我發現在

訓練過程中，阻礙 dice score 上升的關鍵因素在於模型容不容易 overfitting，因此若要改善分數，可以優先從這個方面著手。

### B. Found any characteristics of the data?

在實驗的過程中，發現 data 很容易進入到 overfitting 的狀態，也就是 training loss 不斷降低，validation loss 卻收斂在偏高的數值。到後面也會有雖然 Dice Score 沒有下降，但是 validation loss 卻不斷上升的狀況，可以看出在 segmentation 的訓練上，如果 overfitting，除了精準度下降之外，可能導致的另一個結果是模型的信心程度越來越低。

## 5. Execution command

以下為 train 的 command:

- UNet: “python3 src/train.py --model UNet --data_path dataset/oxford-iiit-pet --epochs 300 --batch_size 20 --learning_rate 0.001”

- ResNet34_UNet: “python3 src/train.py --model ResNet34_UNet --data_path dataset/oxford-iiit-pet --epochs 300 --batch_size 60 --learning_rate 0.001”

以下為 test(inference)的 command:

--model: 參數路徑；--data_path: 資料集路徑；-batch_size: 批次大小，預設 1 避免爆記憶體

- UNet: “python3 src/inference.py --model saved_models/DL_Lab3_UNet_112550069_謝侑哲.pth --data_path dataset/oxford-iiit-pet --batch_size 1”

- ResNet34_UNet: “python3 src/inference.py --model saved_models/DL_Lab3_ResNet34_UNet_112550069_謝侑哲.pth --data_path dataset/oxford-iiit-pet --batch_size 1”

Inference 得出的結果如下:

```
test loss: 0.2042135173258412, test dice socre: 0.90162334888878714
```

會由程式 print 出 loss 與 dice score

# 6. Analyze on the experiment results

## A. What architecture may bring better results?

以下是 Res34-UNet 與 UNet 在 learning rate 0.001, Adam optimizer，訓練 100 個 epoch 的結果圖。

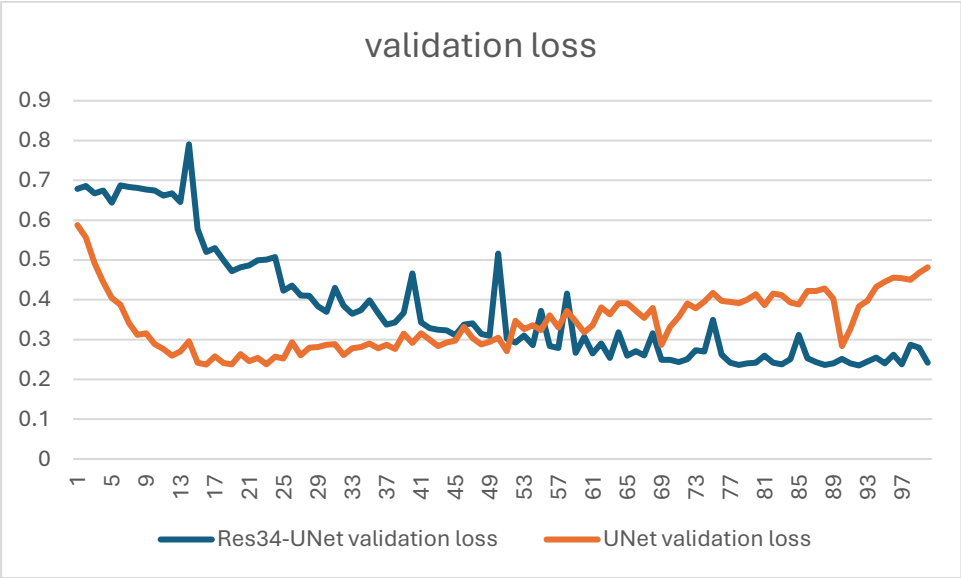


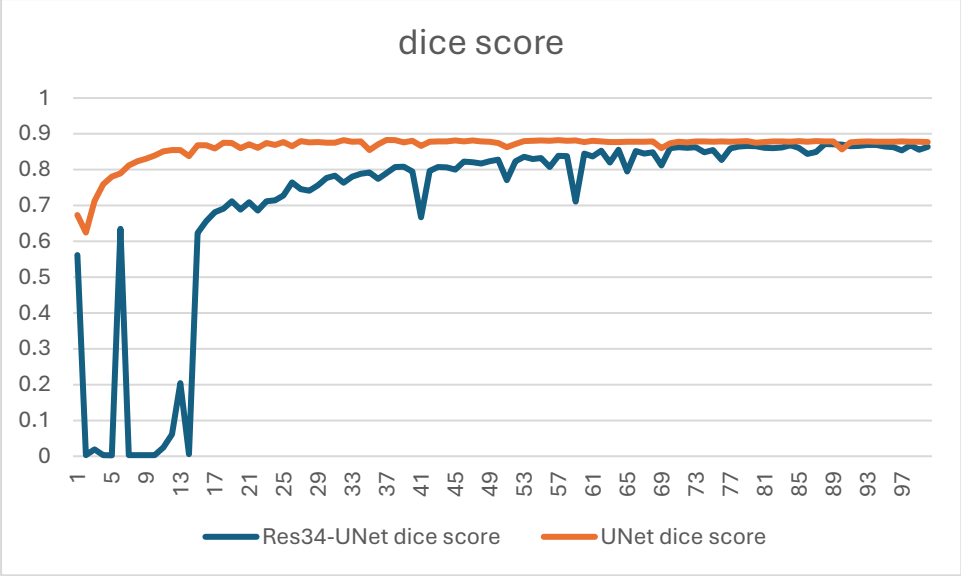


從圖中可以觀察到，UNet 的 validation loss 與 dice score 的收斂速度都比 Res34-UNet 更快。兩者的 dice score 最終收斂在差不多的地方。不過 Res34-UNet 的 validation loss 卻收斂的更低，代表 Res34-UNet 能給出更有信心的答案，整體來看，Res34-UNet 的訓練效果應該更好。並且雖然 UNet 只花更少的 epoch 就可以達到收斂，但是 UNet 訓練一個 epoch 的速度比 Res34-UNet 更

慢，占用的 GPU 記憶體也更多。因此在訓練到同樣收斂的結果時，其實兩者花的時間差不多。

因此可以做出結論，在兩者比較上，Res34-UNet 的模型訓練出來的結果更好，透過 residual mapping 來加深模型，確實讓模型的 capacity 更大，可以分類的更精準一點。

## B. What are the potential research topics in this task?

針對基於 UNet 的圖片 segmentation 任務，我認為潛在的研究議題有三: Encoder、Data Augmentation、Model Depression。

Encoder:

在這次的 LAB 中，第二個 task 是把 ResNet 與 UNet 作為 Encoder、Decoder 拼接在一起，而我也是第一次知道可以用這樣的方式來組合不同的模型。因此，我認為可以嘗試不同的圖片壓縮模型作為 Encoder，諸如: InceptionNet、MobileNet 等等，讓模型在準度、效能上可能有不同的優化，甚至可以套用 Transformer 來做 Encoder，看看 Seq2Seq 的模型跟 UNet 配合的效果怎麼樣，能不能超越傳統上的 CNN-based 模型。

Data Augmentation:

這次 LAB 中，因為時間的關係，我只能簡單實驗 4 種不同的 Data Augmentation 方式，不過這次我遇到了明顯的 Overfitting，因此我認為可以在 Data Augmentation 上面做更多的實驗，包括我這次未能做到的角度旋轉、翻轉等等的操作，試著讓模型的 generalization 能力上升。

Model Depression:

這次的 LAB 中，我遇到的一個大問題是，顯卡的記憶體用來訓練 UNet 等模型並不是很夠用，很容易不小心就爆記憶體。實際上或許解決 segmentation 任務可以不需要這麼多的參數。因此我認為可以針對模型的壓縮著手，尋找方式壓縮模型的參數量，或者是替換成 MobileNet 之類的更節能的 Encoder 等等。